
Théorie des Ondelettes

Historique, fondements mathématiques, familles et applications

Cours rédigé pour Yassine
M2 Quantitative Finance — Paris-Dauphine PSL

31 mai 2026

Résumé

Ce document constitue un cours complet sur la théorie des ondelettes, depuis ses origines historiques jusqu'à ses applications modernes en traitement du signal et en finance quantitative. Nous commençons par motiver l'introduction des ondelettes comme remède aux limitations de l'analyse de Fourier classique. Nous développons ensuite le cadre mathématique de la transformée continue, puis discrète, en passant par l'analyse multi-résolution de Mallat-Meyer. Les principales familles d'ondelettes (Haar, Daubechies, Symlets, Coiflets, Meyer, biorthogonales) sont présentées avec leurs propriétés respectives. Nous traitons enfin des applications, notamment le débruitage et la détection de structures multi-échelles en finance, en lien avec la stratégie de pairs trading par ondelettes de Eroğlu, Yener et Yigit (2023). Le document est rédigé à un niveau Master, supposant une familiarité avec l'analyse fonctionnelle de base et l'analyse de Fourier élémentaire.

Table des matières

1	Introduction et perspective historique	4
1.1	Pourquoi étudier les ondelettes ?	4
1.2	Une brève histoire	4
2	Motivation : les limites de l'analyse de Fourier	5
2.1	Rappels sur la transformée de Fourier	6
2.2	Le défaut fondamental : pas de localisation temporelle	6
2.3	Le principe d'incertitude de Heisenberg-Gabor	6
2.4	La STFT : première tentative	7
2.5	Pourquoi la STFT ne suffit pas	7
2.6	L'idée des ondelettes	8
3	Transformée continue en ondelettes (CWT)	9
3.1	Définition	9
3.2	Propriétés essentielles	10
3.3	Exemples d'ondelettes continues	10
3.4	Limites de la CWT	10

4	Analyse multi-résolution (MRA)	11
4.1	Définition d'une MRA	11
4.2	Interprétation	11
4.3	Construction des ondelettes à partir de la MRA	12
4.4	Les équations à deux échelles	12
4.5	Conditions sur les filtres	13
5	La transformée discrète en ondelettes (DWT) et l'algorithme pyramidal de Mallat	13
5.1	Idée générale	13
5.2	Formules de récurrence (analyse)	14
5.3	Schéma pyramidal	14
5.4	Reconstruction (synthèse)	15
5.5	Coût computationnel	15
5.6	Le problème du downsampling	15
6	La MODWT	15
6.1	Motivation	15
6.2	Définition formelle	16
6.3	Effets de bord et <i>padding</i>	16
6.4	Décomposition multi-échelle	17
7	Les principales familles d'ondelettes	17
7.1	Haar (1909)	17
7.2	Daubechies (dbN)	18
7.3	Symlets (symN)	18
7.4	Coiflets (coifN)	18
7.5	Ondelettes de Meyer	19
7.6	Ondelettes biorthogonales	19
7.7	Tableau comparatif	19
8	Le débruitage par ondelettes	20
8.1	Modèle	20
8.2	Pourquoi les ondelettes ?	20
8.3	Algorithme de Donoho-Johnstone (1994)	20
8.4	L'approche du papier de pairs trading	20
9	Applications financières	21
9.1	Décomposition multi-échelle des rendements	21
9.2	Mesure de corrélation multi-échelle	21
9.3	Pairs trading avec ondelettes (Eroğlu, Yener, Yiğit 2023)	22
9.4	Autres applications financières	22
10	Limites et alternatives	23
10.1	Limites intrinsèques	23

10.2 Alternatives modernes	23
11 Conclusion	24
Bibliographie commentée	24

1 Introduction et perspective historique

1.1 Pourquoi étudier les ondelettes ?

Les ondelettes (*wavelets* en anglais) constituent l'un des développements les plus marquants de l'analyse mathématique du XX^e siècle. Elles offrent une représentation des signaux qui résout un compromis fondamental, et longtemps perçu comme insurmontable, entre la localisation **temporelle** et la localisation **fréquentielle**.

Concrètement, là où Fourier vous dit quelles fréquences sont présentes dans un signal mais pas *quand* elles apparaissent, les ondelettes répondent simultanément aux questions :

- Quelles structures fréquentielles le signal contient-il ?
- À quel moment chaque structure apparaît-elle ?
- À quelle échelle de durée chaque structure se manifeste-t-elle ?

Cette capacité d'analyse **temps-échelle** (ou **temps-fréquence**) explique l'omniprésence des ondelettes dans des domaines aussi variés que la compression d'image (JPEG 2000), le débruitage de signaux médicaux (ECG, IRM), l'analyse sismique, le pricing d'options stochastiques, ou encore le pairs trading multi-fréquence.

1.2 Une brève histoire

L'histoire des ondelettes est celle d'une convergence improbable entre mathématiciens purs, physiciens, ingénieurs et informaticiens.

1909 — Alfred Haar. Dans sa thèse à l'université de Göttingen, le mathématicien hongrois Alfred Haar construit ce que l'on appellera plus tard « l'ondelette de Haar ». Il s'agit en fait de la première base orthonormée de $L^2([0, 1])$ alternative à la base trigonométrique, fournissant un développement convergent pour toute fonction continue. Haar ne savait pas qu'il venait d'inventer la première ondelette de l'histoire, et son objet resta une curiosité pendant 70 ans.

Années 1930 — Premières intuitions. John Littlewood et Raymond Paley développent une décomposition dyadique de l'espace des fréquences. Bien que leur objectif (étudier les séries de Fourier) soit différent, leur idée préfigure la décomposition multi-échelle.

Années 1940-50 — Gabor et l'analyse temps-fréquence. Le physicien Dennis Gabor introduit en 1946 la **transformée de Fourier à fenêtre** (STFT). C'est une amélioration de Fourier classique — on regarde des morceaux du signal — mais avec une limitation fondamentale : la fenêtre est de taille fixe, imposée *a priori*.

1975 — Jean Morlet et la sismique. Un ingénieur géophysicien français, Jean Morlet, travaille pour Elf-Aquitaine sur l'analyse de signaux sismiques destinés à la prospection pétrolière. Frustré par les limites de la STFT, il a une intuition décisive : *au lieu de garder une fenêtre fixe et de faire varier la fréquence des oscillations à l'intérieur, gardons une forme d'onde fixe et dilatons-la*. Morlet baptise ces fonctions *ondelettes* (en anglais *wavelets*). Il développe la transformée empiriquement, sans cadre mathématique rigoureux.

1984 — Grossmann et Morlet. Le physicien Alex Grossmann (CNRS, Marseille) formalise les

idées de Morlet et démontre que la transformée en ondelettes continue est une isométrie (à une constante près) entre $L^2(\mathbb{R})$ et un certain espace de fonctions sur le demi-plan temps-échelle. C'est l'acte de naissance officiel de la théorie.

1985-1986 — Yves Meyer. Le mathématicien français Yves Meyer (futur médaillé Abel 2017), de passage chez le photocopieur de l'École Polytechnique, tombe sur une preprint d'un certain Stromberg construisant une base orthonormée d'ondelettes. Meyer croit la chose impossible en raison de résultats de Balian et Battle ; il vérifie, et découvre la construction. Il généralise alors le résultat en construisant les **ondelettes de Meyer**, C^∞ et à décroissance rapide. C'est la première construction propre d'une base d'ondelettes régulière.

1987 — Stéphane Mallat. À 25 ans, Mallat (alors thésard à l'université de Pennsylvanie) formalise le concept d'**analyse multi-résolution** (MRA). Cette construction est révolutionnaire : elle relie la théorie mathématique des ondelettes au filtrage numérique en bancs de filtres connu des ingénieurs depuis les années 1970 (Esteban, Galand, Smith, Barnwell). Mallat fournit aussi un algorithme rapide — l'algorithme pyramidal — en $O(N)$, plus rapide que la FFT.

1988 — Ingrid Daubechies. La mathématicienne belge Ingrid Daubechies (alors à AT&T Bell Labs) résout un problème central : construire des ondelettes à **support compact**, orthogonales, et de régularité arbitraire. Sa famille **dbN** est aujourd'hui la plus utilisée au monde. Le travail de Daubechies, publié dans *Communications on Pure and Applied Mathematics*, demeure l'une des plus belles synthèses entre théorie et application.

Années 1990 — Explosion applicative. Donoho et Johnstone développent le débruitage par seuillage. Les ondelettes biorthogonales (Cohen, Daubechies, Feauveau) entrent dans le standard JPEG 2000. La théorie s'étend aux espaces de Besov, aux EDP, aux problèmes inverses.

2000-aujourd'hui — Diffusion et raffinement. Les ondelettes deviennent un outil standard, désormais enseigné en école d'ingénieur et utilisé en finance (Gençay, Selçuk, Whitcher, In, Kim), en imagerie médicale, en compression vidéo, en machine learning (scattering transforms de Mallat), etc.

Remarque

La leçon historique est instructive : les ondelettes ont été « découvertes » indépendamment plusieurs fois (Haar 1909, Littlewood-Paley 1930, Calderón 1964, Strömberg 1981, Morlet 1975) avant d'être unifiées entre 1984 et 1989. Ce qui a manqué pendant des décennies, c'est un *langage commun* permettant à l'analyse harmonique, au traitement du signal et à la statistique de se parler. Le concept de MRA de Mallat-Meyer est précisément ce langage.

2 Motivation : les limites de l'analyse de Fourier

Pour comprendre pourquoi les ondelettes ont été inventées, il faut d'abord saisir précisément ce que Fourier ne sait pas faire. Cette section rappelle l'analyse de Fourier, identifie ses limitations, présente la STFT comme première tentative de remède, et explique pourquoi cette tentative reste insuffisante.

2.1 Rappels sur la transformée de Fourier

Transformée de Fourier

Pour $x \in L^1(\mathbb{R}) \cap L^2(\mathbb{R})$, la transformée de Fourier de x est définie par

$$\hat{x}(\omega) = \mathcal{F}[x](\omega) = \int_{-\infty}^{+\infty} x(t) e^{-i\omega t} dt.$$

La transformée inverse est

$$x(t) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} \hat{x}(\omega) e^{i\omega t} d\omega.$$

L'opérateur $\mathcal{F} : L^2(\mathbb{R}) \rightarrow L^2(\mathbb{R})$ est, après renormalisation, une isométrie (théorème de Plancherel) :

$$\|x\|_{L^2}^2 = \frac{1}{2\pi} \|\hat{x}\|_{L^2}^2.$$

Interprétation. $\hat{x}(\omega)$ mesure la « présence » dans le signal x de la sinusoïde $e^{i\omega t}$ de fréquence (angulaire) ω .

2.2 Le défaut fondamental : pas de localisation temporelle

La transformée de Fourier décompose le signal x sur la base des fonctions $\{e^{i\omega t} : \omega \in \mathbb{R}\}$. Ces fonctions ont une propriété cruciale :

$$|e^{i\omega t}| = 1 \quad \text{pour tout } t \in \mathbb{R}.$$

Autrement dit, chaque « brique élémentaire » de la décomposition de Fourier a un support **infini** dans le temps. Conséquence : $\hat{x}(\omega)$ vous indique si la fréquence ω est présente *quelque part* dans le signal, mais ne vous dit pas **où** ni **quand**.

Exemple 2.1 (Le contre-exemple instructif). *Considérons deux signaux sur $[0, 4]$:*

- $x_1(t) = \sin(2\pi t) \cdot \mathbf{1}_{[0,2]}(t) + \sin(8\pi t) \cdot \mathbf{1}_{[2,4]}(t)$: une fréquence basse puis une fréquence haute.
- $x_2(t) = \sin(8\pi t) \cdot \mathbf{1}_{[0,2]}(t) + \sin(2\pi t) \cdot \mathbf{1}_{[2,4]}(t)$: une fréquence haute puis une fréquence basse.

Les deux signaux contiennent les mêmes fréquences globales (1 Hz et 4 Hz), donc leurs spectres $|\hat{x}_1|$ et $|\hat{x}_2|$ sont **quasiment identiques**. Pourtant les signaux sont fondamentalement différents.

C'est dévastateur en finance : si un actif présente une volatilité élevée durant les mois de crise puis basse durant les périodes calmes, ou l'inverse, le spectre de Fourier ne fait pas la différence. Or, économiquement, c'est précisément la différence qui importe.

2.3 Le principe d'incertitude de Heisenberg-Gabor

La limitation observée n'est pas un défaut technique : c'est une **loi mathématique**.

Théorème 2.2 (Principe d'incertitude de Heisenberg-Gabor). *Pour toute fonction $x \in L^2(\mathbb{R})$ avec $\|x\|_{L^2} = 1$, en notant $t_0 = \int t |x(t)|^2 dt$ et $\omega_0 = \frac{1}{2\pi} \int \omega |\hat{x}(\omega)|^2 d\omega$ les barycentres temporel et*

fréquentiel, on définit les écarts

$$\Delta_t^2 = \int (t - t_0)^2 |x(t)|^2 dt, \quad \Delta_\omega^2 = \frac{1}{2\pi} \int (\omega - \omega_0)^2 |\hat{x}(\omega)|^2 d\omega.$$

Alors

$$\Delta_t \cdot \Delta_\omega \geq \frac{1}{2}.$$

L'égalité est atteinte si et seulement si x est une gaussienne (modulée et translatée).

Conséquence philosophique. Aucun outil d'analyse ne peut être arbitrairement précis simultanément en temps et en fréquence. Le mieux que l'on puisse espérer est de **choisir** comment partitionner cette incertitude irréductible. Fourier alloue 0% de localisation au temps et 100% à la fréquence. C'est un choix extrême, et il existe d'autres choix.

2.4 La STFT : première tentative

L'idée la plus naturelle pour récupérer un peu d'information temporelle est de **fenêtrer** le signal avant d'appliquer Fourier. C'est la **Short-Time Fourier Transform** (STFT), aussi appelée **transformée de Gabor**.

STFT

Étant donnée une fonction fenêtre $g \in L^2(\mathbb{R})$ (en général une gaussienne, centrée en zéro, à support pseudo-compact), la STFT du signal x est

$$G_x(b, \omega) = \int_{-\infty}^{+\infty} x(t) \overline{g(t-b)} e^{-i\omega t} dt.$$

L'idée : $g(t-b)$ est la fenêtre translatée en b . La STFT mesure le contenu fréquentiel du signal *au voisinage de l'instant b* .

2.5 Pourquoi la STFT ne suffit pas

La STFT améliore Fourier, mais elle souffre d'un défaut majeur : **la taille de la fenêtre g est fixée une fois pour toutes**.

Représentons cela schématiquement dans le plan temps-fréquence (*Heisenberg boxes*) :



STFT : toutes les boîtes sont de même taille

C'est inadapté pour la plupart des signaux réels qui combinent :

- Des composantes **basse fréquence** (tendance lente) qui s'étalent sur de longues durées — besoin d'une fenêtre large temporellement.
- Des composantes **haute fréquence** (transitoires, ruptures, bursts) très brèves — besoin d'une fenêtre étroite temporellement.


Avec une fenêtre fixe :

- Fenêtre étroite (g très localisée) : bonne résolution temporelle mais mauvaise résolution fréquentielle pour les basses fréquences (on perd l'information de tendance).
- Fenêtre large : bonne résolution fréquentielle mais on ne distingue plus deux événements rapprochés dans le temps.

2.6 L'idée des ondelettes

Plutôt que d'avoir une fenêtre de taille fixe contenant plus ou moins d'oscillations selon la fréquence, gardons une forme d'onde fixe et faisons varier sa taille.

Concrètement, on part d'une fonction ψ (l'**ondelette mère**) et on l'utilise à plusieurs échelles : version « compressée » de ψ pour les hautes fréquences (localisée temporellement), version « étirée » de ψ pour les basses fréquences (étalée temporellement).



Ondelettes : boîtes adaptées à l'échelle

Cette adaptation est exactement ce que prescrit la pratique : pour les fréquences hautes, on accepte

de moins bien localiser fréquentiellement (boîtes hautes mais fines temporellement) ; pour les fréquences basses, on accepte de moins bien localiser temporellement (boîtes étalées mais fines fréquentiellement). Le produit $\Delta_t \cdot \Delta_\omega$ reste constant $\geq 1/2$ partout, conformément à Heisenberg-Gabor.

3 Transformée continue en ondelettes (CWT)

3.1 Définition

Ondelette mère

Une fonction $\psi \in L^2(\mathbb{R})$ est appelée **ondelette mère** (ou *mother wavelet*) si elle satisfait :

- (i) ψ est de carré intégrable : $\psi \in L^2(\mathbb{R})$.
- (ii) **Condition d'admissibilité** :

$$C_\psi := \int_0^{+\infty} \frac{|\hat{\psi}(\omega)|^2}{|\omega|} d\omega < +\infty.$$

Proposition 3.1 (Conséquence de l'admissibilité). *Si ψ est admissible et $\hat{\psi}$ est continue à l'origine, alors $\hat{\psi}(0) = 0$, c'est-à-dire*

$$\int_{-\infty}^{+\infty} \psi(t) dt = 0.$$

Démonstration. Si $\hat{\psi}(0) \neq 0$, par continuité $|\hat{\psi}(\omega)|^2 \geq c > 0$ sur un voisinage de zéro, ce qui rend C_ψ infinie ($\int 1/|\omega| d\omega$ diverge près de zéro). $\square$

Interprétation. L'ondelette mère doit « osciller » (moyenne nulle) et avoir une « forme localisée ». C'est le minimum pour qu'elle puisse jouer le rôle de détecteur de variations locales.

Famille d'ondelettes par dilatation-translation

À partir de ψ , on définit la famille

$$\psi_{a,b}(t) = \frac{1}{\sqrt{|a|}} \psi\left(\frac{t-b}{a}\right), \quad a \in \mathbb{R}^*, b \in \mathbb{R}.$$

Le paramètre a est le facteur d'**échelle** (ou de *dilatation*), b est le paramètre de **translation**.

Le facteur $1/\sqrt{|a|}$ assure que $\|\psi_{a,b}\|_{L^2} = \|\psi\|_{L^2}$.

Transformée continue en ondelettes (CWT)

Pour $x \in L^2(\mathbb{R})$, la transformée continue en ondelettes de x associée à ψ est

$$W_x(a,b) = \langle x, \psi_{a,b} \rangle = \int_{-\infty}^{+\infty} x(t) \overline{\psi_{a,b}(t)} dt = \frac{1}{\sqrt{|a|}} \int x(t) \overline{\psi\left(\frac{t-b}{a}\right)} dt.$$

3.2 Propriétés essentielles

Théorème 3.2 (Formule d'inversion et conservation d'énergie). *Si ψ est admissible, alors pour tout $x \in L^2(\mathbb{R})$:*

$$x(t) = \frac{1}{C_\psi} \int_{-\infty}^{+\infty} \int_0^{+\infty} W_x(a, b) \psi_{a,b}(t) \frac{da db}{a^2}, \quad (1)$$

$$\|x\|_{L^2}^2 = \frac{1}{C_\psi} \int_{-\infty}^{+\infty} \int_0^{+\infty} |W_x(a, b)|^2 \frac{da db}{a^2}. \quad (2)$$

Interprétation. La CWT est une isométrie de $L^2(\mathbb{R})$ vers $L^2(\mathbb{R} \times \mathbb{R}_+^*, db da / (C_\psi a^2))$. Tout signal peut être reconstruit à partir de ses coefficients d'ondelettes.

3.3 Exemples d'ondelettes continues

Ondelette de Haar

La plus simple :

$$\psi^H(t) = \begin{cases} +1 & \text{si } 0 \leq t < 1/2, \\ -1 & \text{si } 1/2 \leq t < 1, \\ 0 & \text{sinon.} \end{cases}$$

Discontinue. Sert essentiellement de cas pédagogique — mais aussi de cas limite des Daubechies (db1 = Haar).

Ondelette de Morlet

$$\psi^M(t) = \pi^{-1/4} e^{i\omega_0 t} e^{-t^2/2}.$$

C'est une gaussienne modulée par une exponentielle complexe. Très utilisée en CWT pour l'analyse temps-fréquence (en sismique, en finance pour les analyses spectrales). Atteint l'optimum dans l'inégalité de Heisenberg-Gabor.

Ondelette « Mexican hat »

$$\psi(t) = \frac{2}{\sqrt{3}\pi^{1/4}} (1 - t^2) e^{-t^2/2}.$$

C'est la dérivée seconde de la gaussienne (à un signe près). Très utilisée en détection de bords et de pics.

3.4 Limites de la CWT

La CWT a deux limitations sérieuses pour les applications pratiques :

1. **Redondance massive.** Pour un signal de dimension N , la CWT produit une fonction de deux variables (a, b) : on a une explosion exponentielle de l'information. Coûteux à stocker et calculer.

2. **Pas naturellement adaptée aux données discrètes.** Les données financières (ou tout signal échantillonné) vivent sur $\mathbb{Z}$, pas sur $\mathbb{R}$.

D'où le développement des transformées **discrètes** en ondelettes (DWT, MODWT), qui utilisent une grille dyadique de paramètres (a, b) .

4 Analyse multi-résolution (MRA)

L'analyse multi-résolution, introduite par Mallat et Meyer en 1986-89, est le cadre mathématique qui unifie ondelettes continues, ondelettes discrètes et bancs de filtres numériques. C'est sans doute la construction la plus élégante de toute la théorie des ondelettes.

4.1 Définition d'une MRA

Analyse multi-résolution (Mallat-Meyer)

Une **analyse multi-résolution** de $L^2(\mathbb{R})$ est une suite $(V_j)_{j \in \mathbb{Z}}$ de sous-espaces fermés de $L^2(\mathbb{R})$ satisfaisant :

(M1) **Emboîtement** : $\dots \subset V_2 \subset V_1 \subset V_0 \subset V_{-1} \subset V_{-2} \subset \dots$

(M2) **Densité** : $\overline{\bigcup_{j \in \mathbb{Z}} V_j} = L^2(\mathbb{R})$.

(M3) **Séparation** : $\bigcap_{j \in \mathbb{Z}} V_j = \{0\}$.

(M4) **Auto-similarité** : $f(t) \in V_j \iff f(2t) \in V_{j-1}$.

(M5) **Translation** : $f(t) \in V_0 \iff f(t - k) \in V_0$ pour tout $k \in \mathbb{Z}$.

(M6) **Existence d'une fonction d'échelle** : il existe $\varphi \in V_0$ telle que $\{\varphi(\cdot - k)\}_{k \in \mathbb{Z}}$ est une base orthonormée de V_0 .

La fonction φ est appelée **fonction d'échelle** (*scaling function*, ou *father wavelet*).

Conventions de signe

Attention : certains auteurs (Daubechies) indexent les V_j à l'envers, c'est-à-dire $V_j \subset V_{j+1}$. Nous suivons ici la convention de Mallat, plus courante en signal, où V_j devient « plus grossier » quand j augmente.

4.2 Interprétation

- Chaque V_j est un sous-espace de « fonctions à résolution 2^j » : il contient les fonctions qui apparaissent « lisses » à l'échelle 2^j .
- L'emboîtement (M1) dit que plus on *descend* dans les indices ($j \rightarrow -\infty$), plus on a de résolution. À la limite, on récupère tout L^2 (M2). À l'autre extrême ($j \rightarrow +\infty$), on perd toute information (M3).
- L'auto-similarité (M4) dit que tous les niveaux de résolution sont structurellement identiques, à un changement d'échelle près.
- L'invariance par translation (M5) dit que la résolution est uniforme sur l'axe temporel.
- (M6) fournit une représentation explicite.

À partir de φ , posons

$$\varphi_{j,k}(t) = 2^{-j/2} \varphi(2^{-j}t - k), \quad k \in \mathbb{Z}.$$

On vérifie facilement (via M4) que $\{\varphi_{j,k}\}_{k \in \mathbb{Z}}$ est une base orthonormée de V_j .

4.3 Construction des ondelettes à partir de la MRA

Espace de détails W_j

On définit W_j comme le complément orthogonal de V_j dans V_{j-1} :

$$V_{j-1} = V_j \oplus W_j, \quad W_j \perp V_j.$$

Par récurrence :

$$V_{j-1} = V_j \oplus W_j = (V_{j+1} \oplus W_{j+1}) \oplus W_j = \cdots = V_J \oplus \bigoplus_{k=j}^J W_k.$$

En faisant $J \rightarrow +\infty$ et $j \rightarrow -\infty$, on obtient la **décomposition fondamentale** :

$$L^2(\mathbb{R}) = \bigoplus_{j \in \mathbb{Z}} W_j.$$

Théorème 4.1 (Existence d'une ondelette mère). *Si $(V_j)_{j \in \mathbb{Z}}$ est une MRA de fonction d'échelle φ , alors il existe $\psi \in W_0$ telle que $\{\psi(\cdot - k)\}_{k \in \mathbb{Z}}$ est une base orthonormée de W_0 . Par conséquent, $\{\psi_{j,k}\}_{j,k \in \mathbb{Z}}$ est une base orthonormée de $L^2(\mathbb{R})$.*

La fonction ψ est l'**ondelette mère** associée à la MRA, et φ est la **fonction d'échelle**.

4.4 Les équations à deux échelles

Puisque $\varphi \in V_0 \subset V_{-1}$ et que $\{\varphi_{-1,k}\}_k$ est base orthonormée de V_{-1} , on peut développer φ dans cette base :

$$\varphi(t) = \sqrt{2} \sum_{k \in \mathbb{Z}} h_k \varphi(2t - k).$$

C'est l'**équation de dilatation** (ou *two-scale equation*) ; les $(h_k)_{k \in \mathbb{Z}}$ sont les **coefficients du filtre passe-bas** (ou *scaling coefficients*).

De même, $\psi \in W_0 \subset V_{-1}$, donc

$$\psi(t) = \sqrt{2} \sum_{k \in \mathbb{Z}} g_k \varphi(2t - k).$$

Les (g_k) sont les coefficients du **filtre passe-haut** (ou *wavelet coefficients*).

Théorème 4.2 (Relation entre les deux filtres). *Pour que ψ soit orthogonale aux translatées de φ ,*

les coefficients h_k et g_k doivent satisfaire la **relation de quadrature miroir (QMF)** :

$$g_k = (-1)^k h_{1-k},$$

ou, plus généralement pour un filtre de longueur L ,

$$g_k = (-1)^k h_{L-1-k}.$$

Conséquence cruciale. Toute la théorie se réduit, du point de vue calculatoire, à un choix de coefficients $(h_k)_k$ vérifiant certaines conditions (somme égale à $\sqrt{2}$, orthogonalité des translatées, régularité, etc.). Une fois ces h_k choisis, g_k s'en déduit, et φ et ψ sont déterminées (au moins implicitement).

4.5 Conditions sur les filtres

Pour qu'une suite (h_k) engendre une MRA orthonormée valide, elle doit satisfaire :

(C1) **Normalisation** : $\sum_k h_k = \sqrt{2}$.

(C2) **Orthogonalité des translatées** : $\sum_k h_k h_{k+2m} = \delta_{m,0}$.

(C3) **Annulation moyenne du filtre passe-haut** : $\sum_k g_k = 0$.

(C4) **Régularité (optionnelle mais souhaitable)** : nombre N de *moments nuls* de ψ :

$$\int t^p \psi(t) dt = 0 \quad \text{pour } p = 0, 1, \dots, N-1,$$

ce qui équivaut à

$$\sum_k k^p g_k = 0 \quad \text{pour } p = 0, 1, \dots, N-1.$$

Remarque 4.3 (Pourquoi les moments nuls comptent). *Un filtre avec N moments nuls « annihile » les signaux polynomiaux de degré $< N$. Concrètement : si votre signal est constitué d'une tendance polynomiale plus du bruit, seules les déviations par rapport à cette tendance produiront des coefficients d'ondelettes significatifs. C'est la propriété qui rend les ondelettes excellentes pour le **débruitage** et la **détection de ruptures** : la masse des coefficients se concentre sur les vraies discontinuités du signal.*

5 La transformée discrète en ondelettes (DWT) et l'algorithme pyramidal de Mallat

L'algorithme pyramidal de Mallat (1989) est ce qui a fait passer les ondelettes du statut d'objet mathématique à celui d'outil de calcul. Il fournit une méthode en $O(N)$ pour décomposer (et reconstruire) un signal discret en ses composantes d'ondelettes.

5.1 Idée générale

On part d'un signal discret $\mathbf{x} = (x_0, x_1, \dots, x_{N-1})$ avec $N = 2^J$. On l'identifie aux coefficients $a_k^{(0)} := x_k$ de la projection sur le sous-espace V_0 d'une MRA.

L'algorithme calcule récursivement les coefficients $(a_k^{(j)})_k$ (approximations à l'échelle j) et $(d_k^{(j)})_k$ (détails à l'échelle j) pour $j = 1, 2, \dots, J$.

5.2 Formules de récurrence (analyse)

Récurrence pyramidale — décomposition

Étant donnés les coefficients d'approximation $(a_k^{(j-1)})$ à l'échelle $j - 1$, ceux de l'échelle j sont :


$$a_n^{(j)} = \sum_k h_{k-2n} a_k^{(j-1)}, \quad (\text{approximation}) \quad (3)$$

$$d_n^{(j)} = \sum_k g_{k-2n} a_k^{(j-1)}. \quad (\text{détail}) \quad (4)$$

Ces formules s'interprètent en deux étapes :

1. **Filtrage** : convolution de $a^{(j-1)}$ avec h (pour l'approximation) et avec g (pour le détail).
2. **Sous-échantillonnage par 2** (*downsampling*) : on ne conserve qu'un coefficient sur deux.

5.3 Schéma pyramidal



h = filtre passe-bas

g = filtre passe-haut

↓ 2 sous-échantillonnage

Décomposition finale : après J étapes, on a remplacé les N coefficients d'origine par

$$(a^{(J)}, d^{(J)}, d^{(J-1)}, \dots, d^{(1)}),$$

qui contiennent au total N coefficients (la transformation est inversible et préserve la dimension).

5.4 Reconstruction (synthèse)

Récurrance pyramidale — reconstruction

À partir de $(a^{(j)}, d^{(j)})$, on reconstruit $a^{(j-1)}$ par :

$$a_k^{(j-1)} = \sum_n h_{k-2n} a_n^{(j)} + \sum_n g_{k-2n} d_n^{(j)}.$$

Cette étape s'interprète comme un **sur-échantillonnage par 2** (insertion de zéros) suivi d'un filtrage par les filtres miroirs.

5.5 Coût computationnel

À chaque niveau j , le calcul est en $O(N_j)$ avec $N_j = N/2^j$. Le coût total est

$$O(N) + O(N/2) + O(N/4) + \dots = O(N).$$

C'est **plus rapide que la FFT** (qui est en $O(N \log N)$). Spectaculaire pour une transformée orthogonale.

5.6 Le problème du downsampling

L'algorithme pyramidal de Mallat a un défaut pour les applications en séries temporelles : à chaque niveau, on perd la moitié des coefficients. À l'échelle j , on n'a plus que $N/2^j$ coefficients.

Conséquences pour l'analyse de séries temporelles :

- Perte d'alignement temporel précis entre les niveaux.
- Sensibilité à la **translation** du signal d'entrée : si on décale $\mathbf{x}$ d'un pas, les coefficients changent radicalement (la DWT n'est pas équivariante par translation).
- Difficulté à interpréter visuellement les détails à différentes échelles.

C'est précisément pour ces raisons que la MODWT (Maximum Overlap DWT) a été introduite et qu'elle est universellement préférée en finance.

6 La MODWT

6.1 Motivation

La **Maximum Overlap Discrete Wavelet Transform** (MODWT), aussi connue sous les noms de *stationary wavelet transform* (SWT), *undecimated DWT*, ou *algorithme à trous*, supprime le downsampling de la DWT classique.

Conséquences :

- Conservation de la taille d'échantillon à tous les niveaux : si l'entrée a N points, chaque niveau a aussi N coefficients.
- **Équivariance par translation** : un décalage temporel du signal induit un décalage identique des coefficients (propriété essentielle pour les applications financières temps réel).
- Pas de contrainte de longueur dyadique sur le signal.

— Variance réduite des estimateurs spectraux et de covariance dérivés des ondelettes.

Coût : la MODWT est **redondante**. Au lieu de N coefficients au total comme la DWT, elle produit $N \cdot J$ coefficients pour J niveaux. Ce n'est plus une base orthonormée, mais une *frame* (cadre). Le coût computationnel est $O(N \log_2 N)$ au lieu de $O(N)$ — toujours raisonnable.

6.2 Définition formelle

Filtres MODWT

Étant donnés les filtres DWT h et g , on définit les **filtres MODWT** par

$$\tilde{h}_l = h_l / \sqrt{2}, \quad \tilde{g}_l = g_l / \sqrt{2}.$$

La renormalisation par $\sqrt{2}$ compense l'absence de downsampling pour préserver les normes.

Récurrence MODWT

Soit $\tilde{a}_t^{(0)} = x_t$. Pour $j = 1, 2, \dots, J$:

$$\tilde{a}_t^{(j)} = \sum_{l=0}^{L-1} \tilde{h}_l \tilde{a}_{t-2^{j-1}l}^{(j-1)} \mod N \quad (5)$$

$$\tilde{d}_t^{(j)} = \sum_{l=0}^{L-1} \tilde{g}_l \tilde{a}_{t-2^{j-1}l}^{(j-1)} \mod N \quad (6)$$

Points clés :

- Pas de sous-échantillonnage. La taille reste N à chaque niveau.
- Le décalage $2^{j-1}l$ correspond au *upsampling* progressif des filtres (insertion de zéros entre les coefficients du filtre). C'est l'algorithme « à trous ».
- L'arithmétique modulo N implique une convolution **circulaire**, ce qui pose le problème des effets de bord (voir section suivante).

6.3 Effets de bord et *padding*

La convolution circulaire est artificielle pour une série temporelle. Aux extrémités du signal, les coefficients sont « pollués » par le repliement. Solutions classiques :

- **Zero padding** : on étend le signal par des zéros. Introduit des discontinuités artificielles.
- **Periodic padding** : on périodise. Inadapté si le signal n'est pas naturellement périodique.
- **Symmetric padding** : on prolonge par réflexion miroir. Évite les discontinuités. **C'est le choix de Eroğlu, Yener et Yiğit (2023)** dans leur application en pairs trading.
- **Smooth padding** : extension polynomiale (linéaire, cubique).

Règle pratique : en finance temps réel, ne jamais prendre de décision de trading sur les derniers coefficients d'un niveau profond, car ils dépendent fortement du *padding*.

6.4 Décomposition multi-échelle

Après J niveaux de MODWT, on obtient la décomposition

$$x_t = \tilde{a}_t^{(J)} + \sum_{j=1}^J \tilde{d}_t^{(j)} \quad (\text{reconstruction parfaite}).$$

Cette décomposition sépare le signal en :

- Une **tendance** $\tilde{a}^{(J)}$ à l'échelle 2^J (long terme),
- Des **détails** $\tilde{d}^{(j)}$ à chaque échelle $2^{j-1} \leftrightarrow 2^j$.

Pour un signal échantillonné à fréquence quotidienne :

Niveau	Échelle (jours)	Interprétation économique
$\tilde{d}^{(1)}$	1–2	Bruit de microstructure intra-jour, news
$\tilde{d}^{(2)}$	2–4	Fluctuations très court terme
$\tilde{d}^{(3)}$	4–8	Cycle hebdomadaire
$\tilde{d}^{(4)}$	8–16	Cycle bi-hebdomadaire
$\tilde{d}^{(5)}$	16–32	Cycle mensuel
$\tilde{d}^{(6)}$	32–64	Cycle bi-mensuel à trimestriel
$\tilde{a}^{(6)}$	> 64	Tendance de fond

7 Les principales familles d'ondelettes

Une fois le cadre MRA établi, construire une ondelette se réduit à choisir des coefficients (h_k) satisfaisant certaines contraintes. Différents choix donnent différents **compromis** entre régularité, support compact, symétrie, nombre de moments nuls, etc. Aucune famille n'est universellement supérieure ; le choix dépend de l'application.

7.1 Haar (1909)

Filtre : $h = (1/\sqrt{2}, 1/\sqrt{2})$, $g = (1/\sqrt{2}, -1/\sqrt{2})$.

Ondelette mère : $\psi^H(t) = +1$ sur $[0, 1/2)$, -1 sur $[1/2, 1)$, 0 ailleurs.

Fonction d'échelle : $\varphi(t) = \mathbf{1}_{[0,1)}(t)$ (fonction indicatrice).

Propriétés :

- Support compact $[0, 1]$.
- Symétrique.
- 1 seul moment nul ($\int \psi = 0$).
- **Discontinue** — mauvaise pour les signaux lisses.
- Excellente localisation temporelle, mauvaise localisation fréquentielle.

Usage : essentiellement pédagogique, parfois utilisée en détection de ruptures abruptes (changements de régime, signaux binaires).

7.2 Daubechies (dbN)

Construites par Ingrid Daubechies en 1988. Famille la plus utilisée au monde.

Construction : étant donné $N \geq 1$, dbN est l'unique ondelette orthonormée à support compact de longueur $2N - 1$ ayant exactement N moments nuls et phase minimale.

Cas db1 : c'est l'ondelette de Haar.

Cas db2 : coefficients du filtre passe-bas

$$h_0 = \frac{1 + \sqrt{3}}{4\sqrt{2}}, \quad h_1 = \frac{3 + \sqrt{3}}{4\sqrt{2}}, \quad h_2 = \frac{3 - \sqrt{3}}{4\sqrt{2}}, \quad h_3 = \frac{1 - \sqrt{3}}{4\sqrt{2}}.$$

On peut vérifier : $\sum h_k = \sqrt{2}$, $\sum h_k h_{k+2} = 0$, $\sum h_k h_k = 1$. Première ondelette continue à support compact !

Propriétés générales :

- Support compact : $[0, 2N - 1]$.
- N moments nuls.
- Orthogonale.
- **Asymétrique** (sauf $N = 1$).
- Régularité croissante avec N .

Compromis : plus N est grand, plus le support est large (moins bonne localisation) mais plus la régularité et le nombre de moments nuls sont élevés (meilleur débruitage).

Usage : débruitage, compression (JPEG-2000 utilise des biorthogonales proches), général.

7.3 Symlets (symN)

Daubechies a démontré un résultat surprenant : **il n'existe pas d'ondelette à la fois orthogonale, à support compact, symétrique et non triviale (autre que Haar).**

Les **Symlets** sont une modification des Daubechies offrant un compromis : elles sont *quasi-symétriques* (le défaut de symétrie est minimisé) tout en conservant les autres propriétés.

Propriétés :

- Longueur $2N$ (un peu plus que dbN).
- N moments nuls.
- Quasi-symétriques.
- Orthogonales et à support compact.

Usage : préférées en finance pour leur quasi-symétrie qui préserve la localisation temporelle des features. **C'est le choix d'Eroğlu, Yener et Yiğit (2023)** : ils utilisent sym22 (longueur 44, 22 moments nuls), Niveau 1, sur les prix S&P 500.

7.4 Coiflets (coifN)

Construites par Daubechies à la demande de Ronald Coifman.

Particularité : non seulement l'ondelette ψ a des moments nuls, mais la **fonction d'échelle** φ a aussi des moments nuls (à part le premier qui vaut 1).

Propriétés :

- Longueur $6N$.
- $2N$ moments nuls pour ψ , $2N$ moments « presque nuls » pour φ .
- Quasi-symétriques.
- Plus longues mais plus régulières que dbN ou symN à N donné.

Usage : méthodes numériques en EDP (où l'on a besoin de bonnes propriétés d'interpolation des coefficients d'approximation), analyse de signaux très lisses.

7.5 Ondelettes de Meyer

Construites par Yves Meyer en 1985. Première construction « propre » d'ondelettes régulières.

Définition : $\hat{\psi}$ a un support compact dans le domaine fréquentiel, $\hat{\psi} \in C^\infty$. Par dualité (Paley-Wiener), ψ est C^∞ et à décroissance plus rapide que tout polynôme.

Propriétés :

- C^∞ (régularité maximale).
- Support **non compact** (mais décroissance très rapide).
- Orthogonale.
- Symétrique.

Usage : analyse mathématique théorique, applications où la régularité prime sur le support compact.

7.6 Ondelettes biorthogonales

Idée : abandonner l'orthogonalité pour gagner symétrie + support compact + régularité. On utilise deux familles $(\psi, \tilde{\psi})$ qui sont biorthogonales :

$$\langle \psi_{j,k}, \tilde{\psi}_{j',k'} \rangle = \delta_{j,j'} \delta_{k,k'}.$$

Usage : standard JPEG-2000 (compression d'images). Les filtres CDF 9/7 et 5/3 sont biorthogonaux.

7.7 Tableau comparatif

Famille	Long.	Mom. nuls	Support cpct	Orth.	Sym.	Régularité
Haar (db1)	2	1	Oui	Oui	Oui	Discontinue
dbN	$2N$	N	Oui	Oui	Non	$\approx 0.2N$
symN	$2N$	N	Oui	Oui	Quasi	$\approx 0.2N$
coifN	$6N$	$2N$	Oui	Oui	Quasi	$\approx 0.4N$
Meyer	∞	∞	Non	Oui	Oui	C^∞
Biortho.	Var.	Var.	Oui	Non	Oui	Var.

8 Le débruitage par ondelettes

L'une des applications les plus puissantes des ondelettes est le **débruitage** (*denoising*). C'est ce qui est exploité dans le papier sur le pairs trading. Cette section explique le principe et les méthodes.

8.1 Modèle

On observe $y_t = x_t + \varepsilon_t$ pour $t = 1, \dots, N$, où x est le « vrai » signal (lisse par morceaux) et ε est un bruit blanc gaussien $\mathcal{N}(0, \sigma^2)$.

Objectif : estimer x à partir de y .

8.2 Pourquoi les ondelettes ?

Deux idées fondamentales :

1. **Parcimonie** : si x est « régulier par morceaux », ses coefficients d'ondelettes sont **rare**s **mais grands** (concentrés sur les discontinuités).
2. **Diffusion du bruit** : le bruit blanc gaussien, lui, se diffuse **uniformément** sur tous les coefficients d'ondelettes. Les coefficients du bruit restent gaussiens avec variance comparable.

Conséquence : dans la représentation en ondelettes, les coefficients d'amplitude élevée appartiennent vraisemblablement au signal, ceux d'amplitude faible appartiennent vraisemblablement au bruit. Il « suffit » donc de seuiller.

8.3 Algorithme de Donoho-Johnstone (1994)

Procédure WaveShrink

1. Calculer la DWT (ou MODWT) de y : coefficients $(w_{j,k})$.
2. Estimer l'écart-type du bruit : $\hat{\sigma} = \text{MAD}(d^{(1)})/0.6745$ (où MAD = median absolute deviation, et $d^{(1)}$ sont les coefficients de détail de niveau 1).
3. Choisir un seuil λ . Donoho-Johnstone proposent le **seuil universel** :

$$\lambda = \hat{\sigma} \sqrt{2 \log N}.$$

4. Appliquer le seuillage. Deux variantes :
 - *Hard thresholding* : $\eta_{\lambda}^H(w) = w \mathbf{1}_{|w| > \lambda}$
 - *Soft thresholding* : $\eta_{\lambda}^S(w) = \text{sign}(w) (|w| - \lambda)_+$
5. Reconstruire le signal par DWT inverse.

Résultat théorique remarquable (Donoho-Johnstone) : cet estimateur est **quasi-optimal** au sens **minimax** sur de très larges classes de fonctions (espaces de Besov), à un facteur $\log N$ près.

8.4 L'approche du papier de pairs trading

Eroğlu, Yener et Yiğit (2023) n'utilisent pas le seuillage. Ils font plus brutal :

- MODWT Niveau 1 avec `sym22`.
- **On ne garde que l'approximation** $\tilde{a}^{(1)}$ (la partie basse fréquence).
- On jette le détail $\tilde{d}^{(1)}$.

Pourquoi cette approche fonctionne malgré sa simplicité :

1. L'objectif n'est pas de reconstruire fidèlement les prix, mais d'**extraire la composante d'équilibre** pour estimer la relation de cointégration.
2. À l'échelle journalière, le bruit de microstructure et les surréactions courtes sont concentrés dans le niveau 1.
3. `sym22` a 22 moments nuls : il préserve très bien les tendances polynomiales (jusqu'au degré 21) tout en éliminant le bruit haute fréquence.

9 Applications financières

9.1 Décomposition multi-échelle des rendements

Étant donnée une série de rendements r_t (par exemple S&P 500), la MODWT permet de décomposer :

$$r_t = \tilde{a}_t^{(J)} + \sum_{j=1}^J \tilde{d}_t^{(j)}.$$

Chaque composante a une interprétation économique :

- $\tilde{a}^{(J)}$: tendance de fond, primes de risque structurelles.
- $\tilde{d}^{(j)}$ pour j grand : cycles macroéconomiques.
- $\tilde{d}^{(j)}$ pour j petit : bruit de microstructure, surréactions.

Gençay, Selçuk et Whitcher (2001) ont popularisé cette approche dans *An Introduction to Wavelets and Other Filtering Methods in Finance and Economics*.

9.2 Mesure de corrélation multi-échelle

La **covariance par ondelettes** entre deux séries x et y à l'échelle j est définie par

$$\widehat{\text{Cov}}_j(x, y) = \frac{1}{N_j} \sum_t \tilde{d}_{x,t}^{(j)} \cdot \tilde{d}_{y,t}^{(j)}.$$

Et la **corrélation par ondelettes** :

$$\hat{\rho}_j(x, y) = \frac{\widehat{\text{Cov}}_j(x, y)}{\sqrt{\widehat{\text{Var}}_j(x) \widehat{\text{Var}}_j(y)}}.$$

Intérêt : la corrélation entre deux actifs peut être très différente à différentes échelles. Par exemple, deux actions peuvent être faiblement corrélées à très court terme (bruit idiosyncratique) mais fortement corrélées à long terme (exposition aux mêmes facteurs macro). La corrélation usuelle agrège tout et masque ces différences.

Application en gestion de portefeuille : construire un portefeuille décorrélé à l'horizon d'investissement (par exemple $j = 4$, soit 8–16 jours) plutôt qu'à toutes les échelles. Approche

pionnière chez Conlon, Cotter et Gençay (2018).

9.3 Pairs trading avec ondelettes (Eroğlu, Yener, Yiğit 2023)

C'est le papier que tu cherches à répliquer. Le principe :

1. **Filtrage MODWT Level 1** des prix S_i et S_j avec `sym22`, on garde $\tilde{V}_i = \tilde{a}_i^{(1)}$ et $\tilde{V}_j$.
2. **Estimation** de la relation de cointégration sur la série filtrée :

$$\tilde{V}_{i,t} = \alpha_w + \beta_w \tilde{V}_{j,t} + \varepsilon_{w,t}.$$

3. **Construction du spread** en trading sur la série filtrée :

$$\hat{\varepsilon}_{w,t} = \tilde{V}_{i,t} - \hat{\alpha}_w - \hat{\beta}_w \tilde{V}_{j,t}.$$

4. **Trading** : ouverture si $|\hat{\varepsilon}_{w,t}| > 2\sigma$ (où σ est l'écart-type calculé sur la training), fermeture au changement de signe.

Pourquoi ça marche : le bruit dans S_i et S_j biaise l'estimation OLS de β (problème classique d'erreur de mesure). Avec :

$$S_{i,t} = S_{i,t}^* + u_{i,t}, \quad S_{j,t} = S_{j,t}^* + u_{j,t},$$

on a $\hat{\beta}_{OLS} \xrightarrow{p} \beta \cdot \frac{\text{Var}(S_j^*)}{\text{Var}(S_j^*) + \text{Var}(u_j)} < \beta$. C'est l'**atténuation classique**.

Le filtrage MODWT élimine la composante haute fréquence (qui contient l'essentiel de u_t), et on retrouve un $\hat{\beta}_w$ proche du vrai β . Le spread reconstruit est alors effectivement stationnaire, et le pairs trading fonctionne.

Résultats empiriques (2010–2018, S&P 500) :

- Sans filtrage : rendement annuel moyen -1.81% (cointégration), -0.55% (min distance).
- Avec `sym22` : rendement annuel moyen $+9.66\%$ et $+11.82\%$ respectivement.
- Sharpe ratios : passage de -0.40 à 2.82 , et de -0.21 à 3.69 .

9.4 Autres applications financières

- **Volatilité réaliste multi-échelle** : décomposition de la volatilité en composantes long/court terme (Andersen-Bollerslev).
- **Détection de bulles** et de changements de régime : les ruptures se manifestent par des coefficients d'ondelettes anormalement grands.
- **Pricing d'options** : pricing par ondelettes pour des EDP type Black-Scholes avec sauts (méthodes Galerkin-ondelettes).
- **Estimation de microstructure** : séparation du « vrai » prix de l'effet microstructure (bid-ask bounce, etc.).
- **Prévision haute fréquence** : modèles AR-ondelettes pour la prévision de séries à différentes échelles.

10 Limites et alternatives

Les ondelettes ne sont pas une panacée. Cette section recense leurs limites et discute des alternatives modernes.

10.1 Limites intrinsèques

1. Effets de bord. Comme déjà mentionné, les coefficients aux extrémités du signal sont biaisés. C'est problématique en trading temps réel où on s'intéresse précisément aux dernières observations. Solutions partielles : padding sophistiqué, modèles spécifiques pour les bords.

2. Choix de l'ondelette. Il n'existe pas de méthode « universelle » pour choisir la famille (db, sym, coif, etc.) ni l'ordre N . Le choix est typiquement empirique, par validation croisée. Ce qui pose un problème de *p-hacking* potentiel en finance (essayer plusieurs ondelettes jusqu'à trouver celle qui fonctionne).

3. Anisotropie en dimension supérieure. En 1D les ondelettes sont excellentes. En 2D ou plus, les ondelettes séparables (produit tensoriel) ne détectent que les contours horizontaux/verticaux et manquent les structures obliques. Les *curvelets* (Candès-Donoho) et *shearlets* (Labate-Lim-Kutyniok) résolvent ce problème.

4. Sensibilité à la translation pour la DWT. La DWT classique n'est pas équivariante par translation. La MODWT corrige ce défaut au prix de la redondance.

5. Non-linéarité. La transformée elle-même est linéaire, mais le seuillage en débruitage est non linéaire. Cela complique l'analyse statistique (intervalles de confiance, etc.).

10.2 Alternatives modernes

Empirical Mode Decomposition (EMD). Méthode entièrement adaptative (les composantes sont extraites du signal sans choix de base *a priori*). Très populaire en ingénierie depuis Huang et al. (1998). Inconvénient : pas de cadre mathématique propre, méthodes essentiellement heuristiques.

Synchrosqueezing. Raffinement de la CWT/STFT qui « concentre » l'énergie autour des vraies fréquences instantanées. Daubechies, Lu, Wu (2011).

Scattering transforms. Combinaisons en cascade de transformées en ondelettes avec des non-linéarités (modulus), introduites par Mallat (2012). Précurseurs des *convolutional neural networks* avec une interprétation mathématique propre.

Réseaux de neurones (LSTM, Transformers). En finance, certains travaux (Flori et Regoli 2021, cités dans le papier) utilisent des LSTM pour le pairs trading. Souvent moins interprétable, mais plus flexible. Les ondelettes peuvent être combinées avec ces approches en *feature engineering*.

Filtres de Kalman et HP filter. Pour la séparation tendance/cycle, les économistes utilisent souvent le filtre de Hodrick-Prescott. Le papier de pairs trading montre toutefois qu'il est inférieur aux ondelettes pour cette application.

11 Conclusion

Les ondelettes représentent l'aboutissement d'un effort centenaire pour résoudre le compromis temps-fréquence. Elles offrent un cadre mathématique élégant (analyse multi-résolution), des algorithmes rapides (pyramide de Mallat), et une boîte à outils très riche (familles de Daubechies, Symlets, Coiflets, etc.).

Pour le quant en finance, les points à retenir sont :

1. Les ondelettes **séparent les échelles temporelles** d'un signal de manière fine et adaptative.
2. La **MODWT** est l'outil de choix pour les séries temporelles : elle préserve la taille d'échantillon et l'équivariance par translation.
3. Le **débruitage par ondelettes** repose sur la parcimonie des coefficients pour les signaux réguliers vs. la diffusion uniforme du bruit.
4. En finance, les ondelettes brillent pour la **décomposition multi-échelle** (Gençay et al.), la **corrélation multi-échelle** (Conlon et al.), et le **débruitage avant estimation économétrique** (Eroğlu et al.).
5. Le choix de la famille et de l'ordre est crucial. Pour l'application en pairs trading, les **Symlets d'ordre élevé** (sym12 à sym24) donnent les meilleurs résultats grâce à leur quasi-symétrie et leur grand nombre de moments nuls.

Les ondelettes ne remplacent pas la statistique classique : elles la complètent en fournissant une représentation alternative du signal mieux adaptée à certains problèmes. Comme tout outil, leur succès dépend de la pertinence avec le problème traité — mais quand elles s'appliquent, elles peuvent transformer un résultat médiocre en un résultat remarquable, comme l'illustre le papier d'Eroğlu, Yener et Yiğit (2023).

Bibliographie commentée

Ouvrages de référence

- **Daubechies, I. (1992)**, *Ten Lectures on Wavelets*, SIAM. Le livre fondateur, par la créatrice des ondelettes à support compact. Mathématique et précis. Indispensable pour comprendre la construction.
- **Mallat, S. (2008)**, *A Wavelet Tour of Signal Processing* (3^e ed.), Academic Press. La référence « côté signal ». Couvre la CWT, la DWT, les bancs de filtres, les bases d'ondelettes en dimension supérieure (curvelets, etc.). Pour aller au-delà de ce cours.
- **Meyer, Y. (1992)**, *Wavelets and Operators*, Cambridge University Press. Approche mathématique pure (analyse harmonique). Difficile mais profond.
- **Vetterli, M. & Kovačević, J. (1995)**, *Wavelets and Subband Coding*, Prentice Hall. Approche par les bancs de filtres. Excellent pour les ingénieurs.

En finance et économie

- **Gençay, R., Selçuk, F. & Whitcher, B. (2001)**, *An Introduction to Wavelets and Other Filtering Methods in Finance and Economics*, Academic Press. La référence en finance.

- Couvre la décomposition multi-échelle des rendements, la covariance par ondelettes, etc.
- **Percival, D.B. & Walden, A.T. (2000)**, *Wavelet Methods for Time Series Analysis*, Cambridge University Press. Traitement statistique des séries temporelles. Excellent sur la MODWT.
 - **In, F. & Kim, S. (2013)**, *An Introduction to Wavelet Theory in Finance : A Wavelet Multiscale Approach*, World Scientific.

Articles séminaux

- **Mallat, S. (1989)**, « A theory for multiresolution signal decomposition : The wavelet representation », *IEEE Trans. PAMI*, 11(7), 674–693. Introduction de la MRA.
- **Daubechies, I. (1988)**, « Orthonormal bases of compactly supported wavelets », *Comm. Pure Appl. Math.*, 41(7), 909–996. Construction des ondelettes à support compact.
- **Donoho, D.L. & Johnstone, I.M. (1994)**, « Ideal spatial adaptation by wavelet shrinkage », *Biometrika*, 81(3), 425–455. Débruitage par seuillage.

Articles cités spécifiquement

- **Eroğlu, B.A., Yener, H. & Yiğit, T. (2023)**, « Pairs trading with wavelet transform », *Quantitative Finance*, 23(7-8), 1129–1154.
- **Conlon, T., Cotter, J. & Gençay, R. (2018)**, « Long-run wavelet-based correlation for financial time series », *European Journal of Operational Research*, 271(2), 676–696.

Logiciels

- **Python : PyWavelets (pywt)**. Contient toutes les familles classiques. La fonction `pywt.swt` implémente la MODWT (à une normalisation près).
- **R : package wavelets (D.B. Percival) et waveslim**. Les plus complets pour les applications statistiques.
- **MATLAB : Wavelet Toolbox**. Très riche, utilisé dans le papier de Eroğlu et al.