

Pairs Trading with Wavelet Transform

Réplication de Eroglu, Yener & Yigit (2023)

Quantitative Finance, 23(7–8), 1129–1154

Yassine Mannai Antonin Bezard Issam Fradi

Université Paris-Dauphine — Master 272

Arbitrage Statistique

5 juin 2026

Plan

- 1 Le papier
- 2 Stratégie
- 3 Pipeline de réplication
- 4 Résultats principaux
- 5 Figures reproduites

Eroglu, Yener & Yigit (2023) — « Pairs trading with wavelet transform », *Quantitative Finance*.

- Le pairs trading classique repose sur un spread de prix qui mélange *tendance* (marche aléatoire) et *bruit haute fréquence*.
- Ce bruit gonfle la variance du spread, brouille les signaux d'entrée/sortie et déclenche des sorties prématurées.
- Idée : remplacer le prix brut par sa **composante lisse d'ondelettes** (MODWT niveau 1+, symlet 20) avant de former le spread. La partie lisse conserve la dynamique lente et écarte la contamination haute fréquence.
- Résultats : 11,82 % (distance) et 9,66 % (cointégration) de rendement moyen par période contre $-0,55$ % et $-1,81$ % pour la variante standard. Sharpe : 3,69 / 2,82 contre $-0,21$ / $-0,40$.
- Univers : S&P 500, point-in-time, 05/03/2010–15/03/2018 (7 périodes annuelles, cf. Table 1 du papier), 415 tickers.

- L'historique est découpé en blocs consécutifs de 252 jours ouvrés.
- Pour chaque période n :
 - formation = bloc k (in-sample),
 - trading = bloc $k + 1$ (out-of-sample).
- La sélection des paires se fait **uniquement** sur le bloc de formation, à partir de l'univers survivant à cette date (aucun look-ahead bias).

Distance	20 paires minimisant $\sum (P_i^* - P_j^*)^2$ sur les prix normalisés.
Cointégration	Test ADF d'Engle-Granger sur $\tilde{P}_i - \alpha - \beta \tilde{P}_j$ après pré-filtre par distance.

L'étape ondelettes

- Chaque série de prix est rééchantillonnée, $\tilde{P}_t = P_t/P_0$.
- MODWT niveau 1+ avec le **symlet sym20**, condition aux bords périodique sur le bloc de trading (fidèle au papier, section 4.4).
- On conserve les **coefficients lisses** (passe-bas), on jette les détails (passe-haut), puis on reconstitue le prix synthétique.
- Le spread de la paire filtrée par ondelettes est alors

$$s_t = \tilde{P}_i^{\text{wav}} - \alpha - \beta \tilde{P}_j^{\text{wav}},$$

avec (α, β) estimés par MCO sur le bloc de formation.

- La variante standard utilise la même formule *sans* l'étape MODWT — c'est la seule différence entre les courbes de chaque figure.

Définition mathématique du filtre MODWT

La **MODWT** (*Maximal Overlap Discrete Wavelet Transform*) au niveau $j = 1$ décompose une série $Z = (Z_0, \dots, Z_{T-1})$ en :

Détails	$\widetilde{W}_{1,t} = \sum_{\ell=0}^{L_1-1} \tilde{h}_\ell Z_{t-\ell \bmod T},$
Lissée	$\widetilde{V}_{1,t} = \sum_{\ell=0}^{L_1-1} \tilde{g}_\ell Z_{t-\ell \bmod T},$

où $\tilde{h}_\ell = h_\ell / \sqrt{2}$ (passe-haut) et $\tilde{g}_\ell = g_\ell / \sqrt{2}$ (passe-bas) sont les filtres orthogonaux de la famille **symlet 20** ($L_1 = 39$ coefficients), normalisés pour conserver l'énergie. Bord traité en périodisant Z .

Propriétés clés pour le pairs trading :

- $\widetilde{V}_{1,t}$ retient les dynamiques *lentes* (≥ 2 jours ouvrés) ; $\widetilde{W}_{1,t}$ (haute fréquence) est écartée.
- **Non-décimé** : série lissée de même longueur T — pas de bord mort, alignement temporel exact.
- Reconstruction parfaite : $Z_t = \widetilde{V}_{1,t} + \widetilde{W}_{1,t}$.
- Invariance par translation — pas de dépendance au point de départ (contrairement à la DWT classique).

Algorithme du pairs trading par ondelettes

Bloc de formation (T_{form} jours)

1. Normaliser les log-prix : $\tilde{P}_t^{(k)} = P_t^{(k)} / P_0^{(k)}$.
2. **Filtrer** : $\tilde{V}_{1,t}^{(k)} \leftarrow \text{MODWT-smooth}(\tilde{P}^{(k)}, \text{sym20})$ pour chaque actif k .
3. Sélectionner les $N = 20$ paires (i, j) minimisant $d_{ij} = T^{-1} \sum_t (\tilde{V}_{1,t}^{(i)} - \tilde{V}_{1,t}^{(j)})^2$.
4. Estimer par MCO : $(\hat{\alpha}_{ij}, \hat{\beta}_{ij}) = \arg \min \sum_t (\tilde{V}_{1,t}^{(i)} - \alpha - \beta \tilde{V}_{1,t}^{(j)})^2$.
5. Spread de formation : $s_t = \tilde{V}_{1,t}^{(i)} - \hat{\alpha}_{ij} - \hat{\beta}_{ij} \tilde{V}_{1,t}^{(j)} \Rightarrow$ calculer μ_s, σ_s .

Bloc de trading (T_{trade} jours)

6. **Re-filtrer** (rolling) : $\tilde{V}_{1,t}^{(k)}$ sur les T_{form} dernières observations.
7. z-score courant : $z_t = (s_t - \mu_s) / \sigma_s$.
8. **Entrée** si $|z_t| > 2$: vendre le jambage haut, acheter le jambage bas, en proportion 1 : $\hat{\beta}_{ij}$.
9. **Sortie** si z_t recroise 0 ou fin de bloc.

Le filtre $\tilde{V}_{1,t}$ est la **seule** modification par rapport au pairs trading classique.

Règle de trading

- Calculer σ du spread sur la fenêtre de formation.
- Entrer dès que $|s_t| > 2\sigma$ (vente du jambage haut, achat du jambage bas).
- Sortir quand s_t recroise zéro pour la première fois.
- Clôture forcée en fin de bloc de trading ; la variante **forced-close-only** de la Table 22 n'utilise aucune autre sortie.
- Coûts de transaction : coût par action appliqué à l'entrée et à la sortie. Nous balayons $tc \in \{0 ; 0,001 ; 0,005\}$ pour les Tables 18–21.

Architecture de la réplication

<code>research/main.py</code>	CLI unifiée. <code>-full</code> = run complet du papier, <code>-tc-sweep</code> = Tables 18–21.
<code>paper_replication/core/</code>	Moteur par période : periods, selection, spread, trading, wavelet, metrics.
<code>paper_replication/analytics/</code>	Régressions d'asset pricing (Fama-French, q-factor, ICAPM de Petkova).
<code>paper_replication/outputs/</code>	22 tables numérotées + 12 figures + résumé de validation.
<code>paper_replication/bootstrap/</code>	Récupération Bloomberg et rafraîchissement des facteurs CSV.

- Polars + numpy + statsmodels (HAC Newey–West), export PNG via matplotlib.
- Sélection des paires et trading : Python pur, déterministe, sans MATLAB.
- 31 tests unitaires (`py -m pytest -q`) couvrant pipeline, tables et seuils de validation.

Chiffres-clés (Tables 4 & 5)

Méthode	Rendement moyen (%)		Sharpe	
	Standard	Ondelettes	Standard	Ondelettes
Distance	−0,55	11,82	−0,21	3,69
Cointégration	−1,81	9,66	−0,40	2,82

Les tolérances de réplcation sont dans `paper_validation_summary.csv` : PASS si $|\Delta\text{mean}| \leq 1,0$ pp et $|\Delta\text{Sharpe}| \leq 0,30$.

Figure 4 — Rendements cumulés en excès

Figure 4 - Cumulative returns (distance)





Figure 4 - Cumulative returns (cointegration)



Gauche : méthode des distances. Droite : méthode de cointégration.

Figure 5 — Ratios de Sharpe quotidiens

Figure 5 - Daily Sharpe-ratio evolution (distance)



Figure 5 - Daily Sharpe-ratio evolution (cointegration)




Figure 8 — Corrélation du bruit filtré

Figure 8 - Filtered-noise variance vs unfiltered return (distance); $\text{corr}=0.19$




Figure 8 - Filtered-noise variance vs unfiltered return (cointegration); $\text{corr}=-0.32$




Figure 9 — Rendements anormaux annuels

Figure 9 - Yearly market-model alpha (distance); green = significant at 5%





Figure 9 - Yearly market-model alpha (cointegration); green = significant at 5%



Merci de votre attention

Code de réplication, slides et sorties :
sous-arbre `research/` du backtesting framework.