

# Pairs Trading with Wavelet Transform

Réplication de Eroglu, Yener & Yigit (2023)

Quantitative Finance, 23(7–8), 1129–1154

Yassine Mannai   Antonin Bezard   Issam Fradi

Université Paris-Dauphine — Master 272

Arbitrage Statistique

5 juin 2026

# Plan

- 1 Le papier
- 2 Stratégie
- 3 Pipeline de réplication
- 4 Résultats principaux
- 5 Figures reproduites

## Eroglu, Yener & Yigit (2023) — « Pairs trading with wavelet transform », *Quantitative Finance*.

- Le pairs trading classique repose sur un spread de prix qui mélange *tendance* (marche aléatoire) et *bruit haute fréquence*.
- Ce bruit gonfle la variance du spread, brouille les signaux d'entrée/sortie et déclenche des sorties prématurées.
- Idée : remplacer le prix brut par sa **composante lisse d'ondelettes** (MODWT niveau 1, symlet d'ordre 22 — sym22) avant de former le spread. La partie lisse conserve la dynamique lente et écarte la contamination haute fréquence.
- Résultats : 11,82 % (distance) et 9,66 % (cointégration) de rendement moyen par période contre  $-0,55$  % et  $-1,81$  % pour la variante standard. Sharpe : 3,69 / 2,82 contre  $-0,21$  /  $-0,40$ .
- Univers : S&P 500, point-in-time, 05/03/2010–15/03/2018 (7 périodes annuelles, cf. Table 1 du papier), 415 tickers.

# Qu'est-ce qu'une ondelette ?

- Une **ondelette**  $\psi$  est une petite onde *localisée* (moyenne nulle, énergie finie) que l'on dilate (échelle  $a$ ) et translate (position  $b$ ) pour sonder un signal :

$$\psi_{a,b}(t) = \frac{1}{\sqrt{a}} \psi\left(\frac{t-b}{a}\right).$$

- **Mécanisme** : corrélér le signal avec  $\psi_{a,b}$  mesure son contenu autour de l'instant  $b$  à l'échelle  $a$ . Petite échelle  $\Rightarrow$  détails rapides (haute fréquence) ; grande échelle  $\Rightarrow$  tendance lente (basse fréquence).
- **Vs Fourier** : les sinus de Fourier sont globaux (aucune localisation temporelle). Les ondelettes sont localisées en *temps ET en fréquence* — idéales pour des séries financières *non stationnaires*.
- **Intérêt en finance** : séparer la tendance (marche aléatoire du prix) du bruit micro-structure haute fréquence ; débruitage, analyse multi-résolution, sans imposer de modèle paramétrique.

# Familles d'ondelettes

---

|                         |                                                                                                   |
|-------------------------|---------------------------------------------------------------------------------------------------|
| <b>Haar</b>             | La plus simple (support 2), discontinue — mauvaise pour des prix lisses.                          |
| <b>Daubechies (dbN)</b> | Support compact $2N$ , $N$ moments nuls, mais fortement <i>asymétriques</i> (déphasage).          |
| <b>Symlets (symN)</b>   | Daubechies « presque symétriques » : déphasage minimal $\Rightarrow$ le prix filtré reste aligné. |
| <b>Coiflets</b>         | Moments nuls aussi sur la fonction d'échelle ; support plus long.                                 |
| <b>Meyer / Morlet</b>   | Très lisses mais à support <i>infini</i> (Morlet est continue).                                   |

---

- Compromis : longueur du support  $L$  vs régularité vs symétrie.
- Le papier choisit un **symlet** : quasi-symétrie  $\Rightarrow$  le prix lissé n'est pas décalé dans le temps par rapport au prix brut (essentiel pour des signaux d'entrée/sortie datés au jour près).

# DWT vs MODWT : pourquoi discret et non-décimé

## Pourquoi *discret* (DWT/MODWT) plutôt que continu (CWT)

La CWT balaie un continuum d'échelles : redondante et coûteuse. Les prix sont échantillonnés quotidiennement  $\Rightarrow$  une transformée à échelles dyadiques discrètes ( $2^j$ ) suffit, est rapide et inversible.

## Pourquoi *MODWT* plutôt que DWT


- **DWT** : décimée (sous-échantillonnage  $\div 2$  par niveau)  $\Rightarrow$  la longueur est divisée par 2, exige  $T = 2^j$ , et *n'est pas* invariante par translation (le résultat dépend du point de départ).
- **MODWT** : *non décimée*  $\Rightarrow$  garde la longueur  $T$  à chaque niveau, fonctionne pour tout  $T$ , est invariante par translation et **aligne exactement** la série lissée sur les jours de trading.

# Pourquoi le symlet d'ordre 22 (sym22)

- Le papier retient le **symlet d'ordre 22** : filtre à  $L = 44$  coefficients.
- **Support long**  $\Rightarrow$  passe-bas très régulier : capte finement la tendance lente et rejette fortement le bruit.
- **Quasi-symétrie**  $\Rightarrow$  distorsion de phase minimale : le prix filtré n'est ni avancé ni retardé par rapport au prix brut.
- **Robustesse** : la Table 16 balaie sym16/sym18/sym20/sym22/db8 — les résultats varient peu, le choix précis de l'ondelette n'est pas critique.
- *Note de réplcation* : PyWavelets ne fournit pas les coefficients exacts du sym22 ; notre code retombe sur **sym20** ( $L = 40$ ), un voisin immédiat couvert par la Table 16.

# Figure 1 — Algorithme pyramidal de Mallat

Figure 1. Pyramid algorithm of Mallat (3-level MODWT decomposition).



Cascade de filtres : à chaque niveau, le passe-bas  $\tilde{g}$  extrait la lissée  $\tilde{V}_j$  (tendance) et le passe-haut  $\tilde{h}$  les détails  $\tilde{W}_j$ . On ne garde que  $\tilde{V}_1$ .



- L'historique est découpé en blocs consécutifs de 252 jours ouvrés.
- Pour chaque période  $n$  :
  - formation = bloc  $k$  (in-sample),
  - trading = bloc  $k + 1$  (out-of-sample).
- La sélection des paires se fait **uniquement** sur le bloc de formation, à partir de l'univers survivant à cette date (aucun look-ahead bias).

---

|                      |                                                                                                        |
|----------------------|--------------------------------------------------------------------------------------------------------|
| <b>Distance</b>      | 20 paires minimisant $\sum_t (\tilde{P}_i - \tilde{P}_j)^2$ sur les prix normalisés.                   |
| <b>Cointégration</b> | Test de <i>Johansen</i> (trace, 5 %) sur $(\tilde{P}_i, \tilde{P}_j)$ , après pré-filtre par distance. |

---

# Sélection des paires : distance & cointégration

Prix normalisés sur le bloc de formation :  $\tilde{P}_{k,t} = P_{k,t}/P_{k,0}$ .

## Méthode 1 — Distance minimale (Gatev et al. 2006)

Pour chaque paire  $(i, j)$ , somme des écarts quadratiques :

$$d_{ij} = \frac{1}{T} \sum_{t=1}^T (\tilde{P}_{i,t} - \tilde{P}_{j,t})^2.$$

On retient les  $N = 20$  paires de plus faible  $d_{ij}$  (doublons de cotation  $d_{ij} \approx 0$  exclus).

## Méthode 2 — Cointégration (test de Johansen)

On teste l'existence d'une relation de long terme via la statistique de **trace** de Johansen sur le vecteur  $(\tilde{P}_{i,t}, \tilde{P}_{j,t})$  :

$$\text{LR}_{\text{trace}}(r=0) > 15,4943 \text{ (valeur critique à 5\%)} \Rightarrow \text{paire cointégrée.}$$

Pré-filtrage par distance (les 2000 paires les plus proches) pour limiter le coût de calcul.

# L'étape ondelettes

- Chaque série de prix est rééchelonnée,  $\tilde{P}_t = P_t/P_0$ .
- MODWT niveau 1 avec le **symlet d'ordre 22 (sym22)**, condition aux bords périodique sur le bloc de trading (fidèle au papier, section 4.4). *Notre réplication retombe sur sym20* (coefficients sym22 non fournis par PyWavelets).
- On conserve les **coefficients lisses** (passe-bas), on jette les détails (passe-haut), puis on reconstitue le prix synthétique.
- Le spread de la paire filtrée par ondelettes est alors

$$s_t = \tilde{P}_i^{\text{wav}} - \alpha - \beta \tilde{P}_j^{\text{wav}},$$

avec  $(\alpha, \beta)$  estimés par MCO sur le bloc de formation.

- La variante standard utilise la même formule *sans* l'étape MODWT — c'est la seule différence entre les courbes de chaque figure.

# Définition mathématique du filtre MODWT

La **MODWT** (*Maximal Overlap Discrete Wavelet Transform*) au niveau  $j = 1$  décompose une série  $Z = (Z_0, \dots, Z_{T-1})$  en :

|         |                                                                                  |
|---------|----------------------------------------------------------------------------------|
| Détails | $\widetilde{W}_{1,t} = \sum_{\ell=0}^{L_1-1} \tilde{h}_\ell Z_{t-\ell \bmod T},$ |
| Lissée  | $\widetilde{V}_{1,t} = \sum_{\ell=0}^{L_1-1} \tilde{g}_\ell Z_{t-\ell \bmod T},$ |

où  $\tilde{h}_\ell = h_\ell/\sqrt{2}$  (passe-haut) et  $\tilde{g}_\ell = g_\ell/\sqrt{2}$  (passe-bas) sont les filtres orthogonaux de la famille **symlet 22** ( $L_1 = 44$  coefficients), normalisés pour conserver l'énergie ( $L_1 = 40$  pour le sym20 de notre réplique). Bord traité en périodisant  $Z$ .

## Propriétés clés pour le pairs trading :

- $\widetilde{V}_{1,t}$  retient les dynamiques *lentes* ( $\geq 2$  jours ouvrés) ;  $\widetilde{W}_{1,t}$  (haute fréquence) est écartée.
- **Non-décimé** : série lissée de même longueur  $T$  — pas de bord mort, alignement temporel exact.
- Reconstruction parfaite :  $Z_t = \widetilde{V}_{1,t} + \widetilde{W}_{1,t}$ .
- Invariance par translation — pas de dépendance au point de départ (contrairement à la DWT classique).

# Algorithme du pairs trading par ondelettes

## Bloc de formation ( $T_{\text{form}}$ jours)

1. Normaliser les log-prix :  $\tilde{P}_t^{(k)} = P_t^{(k)} / P_0^{(k)}$ .
2. **Filtrer** :  $\tilde{V}_{1,t}^{(k)} \leftarrow \text{MODWT-smooth}(\tilde{P}^{(k)}, \text{sym22})$  pour chaque actif  $k$ .
3. Sélectionner les  $N = 20$  paires  $(i, j)$  minimisant  $d_{ij} = T^{-1} \sum_t (\tilde{V}_{1,t}^{(i)} - \tilde{V}_{1,t}^{(j)})^2$ .
4. Estimer par MCO :  $(\hat{\alpha}_{ij}, \hat{\beta}_{ij}) = \arg \min \sum_t (\tilde{V}_{1,t}^{(i)} - \alpha - \beta \tilde{V}_{1,t}^{(j)})^2$ .
5. Spread de formation :  $s_t = \tilde{V}_{1,t}^{(i)} - \hat{\alpha}_{ij} - \hat{\beta}_{ij} \tilde{V}_{1,t}^{(j)} \Rightarrow$  calculer  $\mu_s, \sigma_s$ .

## Bloc de trading ( $T_{\text{trade}}$ jours)

6. **Re-filtrer** (rolling) :  $\tilde{V}_{1,t}^{(k)}$  sur les  $T_{\text{form}}$  dernières observations.
7. z-score courant :  $z_t = (s_t - \mu_s) / \sigma_s$ .
8. **Entrée** si  $|z_t| > 2$  : vendre le jambage haut, acheter le jambage bas, en proportion 1 :  $\hat{\beta}_{ij}$ .
9. **Sortie** si  $z_t$  recroise 0 ou fin de bloc.

Le filtre  $\tilde{V}_{1,t}$  est la **seule** modification par rapport au pairs trading classique.

# Règle de trading

- Calculer  $\sigma$  du spread sur la fenêtre de formation.
- Entrer dès que  $|s_t| > 2\sigma$  (vente du jambage haut, achat du jambage bas).
- Sortir quand  $s_t$  recroise zéro pour la première fois.
- Clôture forcée en fin de bloc de trading ; la variante **forced-close-only** de la Table 22 n'utilise aucune autre sortie.
- Coûts de transaction : coût par action appliqué à l'entrée et à la sortie. Nous balayons  $tc \in \{0 ; 0,001 ; 0,005\}$  pour les Tables 18–21.

# Architecture de la réplication

---

|                                           |                                                                                                 |
|-------------------------------------------|-------------------------------------------------------------------------------------------------|
| <code>research/main.py</code>             | CLI unifiée. <code>-full</code> = run complet du papier, <code>-tc-sweep</code> = Tables 18–21. |
| <code>paper_replication/core/</code>      | Moteur par période : periods, selection, spread, trading, wavelet, metrics.                     |
| <code>paper_replication/analytics/</code> | Régressions d'asset pricing (Fama-French, q-factor, ICAPM de Petkova).                          |
| <code>paper_replication/outputs/</code>   | 22 tables numérotées + 12 figures + résumé de validation.                                       |
| <code>paper_replication/bootstrap/</code> | Récupération Bloomberg et rafraîchissement des facteurs CSV.                                    |

---

- Polars + numpy + statsmodels (HAC Newey–West), export PNG via matplotlib.
- Sélection des paires et trading : Python pur, déterministe, sans MATLAB.
- 41 tests unitaires (`py -m pytest -q`) couvrant pipeline, tables et seuils de validation.

## Chiffres-clés (Tables 4 & 5)

| Méthode       | Rendement moyen (%) |            | Sharpe   |            |
|---------------|---------------------|------------|----------|------------|
|               | Standard            | Ondelettes | Standard | Ondelettes |
| Distance      | −0,55               | 11,82      | −0,21    | 3,69       |
| Cointégration | −1,81               | 9,66       | −0,40    | 2,82       |

Les tolérances de réplcation sont dans `paper_validation_summary.csv` : PASS si  $|\Delta\text{mean}| \leq 1,0$  pp et  $|\Delta\text{Sharpe}| \leq 0,30$ .



# Figure 4 — Rendements cumulés en excès

Figure 4 - Cumulative returns (distance)





Figure 4 - Cumulative returns (cointegration)




Gauche : méthode des distances. Droite : méthode de cointégration.

# Figure 5 — Ratios de Sharpe quotidiens

Figure 5 - Daily Sharpe-ratio evolution (distance)



Figure 5 - Daily Sharpe-ratio evolution (cointegration)



## Figure 8 — Corrélation du bruit filtré

Figure 8 - Filtered-noise variance vs unfiltered return (distance);  $\text{corr}=0.19$





Figure 8 - Filtered-noise variance vs unfiltered return (cointegration);  $\text{corr}=-0.32$



# Figure 9 — Rendements anormaux annuels

Figure 9 - Yearly market-model alpha (distance); green = significant at 5%





Figure 9 - Yearly market-model alpha (cointegration); green = significant at 5%



## **Merci de votre attention**

Code de réplication, slides et sorties :  
sous-arbre `research/` du backtesting framework.