

Pairs Trading par Transformée en Ondelettes

Réplication de Eroglu, Yener & Yigit (2023)

Quantitative Finance, 23(7–8), 1129–1154

Yassine Mannai Antonin Bezard Issam Fradi

Université Paris-Dauphine — Master 272
Arbitrage Statistique

5 juin 2026

Plan

- 1 Le papier
- 2 Stratégie
- 3 Pipeline de réplication
- 4 Résultats principaux
- 5 Figures reproduites
- 6 Bilan

Eroglu, Yener & Yigit (2023) — « Pairs trading with wavelet transform », *Quantitative Finance*.

- Le pairs trading classique repose sur un spread de prix qui mélange *tendance* (marche aléatoire) et *bruit haute fréquence*.
- Ce bruit gonfle la variance du spread, brouille les signaux d'entrée/sortie et déclenche des sorties prématurées.
- Idée : remplacer le prix brut par sa **composante lisse d'ondelettes** (MODWT niveau 1+, symlet 20) avant de former le spread. La partie lisse conserve la dynamique lente et écarte la contamination haute fréquence.
- Résultats : 11,82 % (distance) et 9,66 % (cointégration) de rendement moyen par période contre $-0,55$ % et $-1,81$ % pour la variante standard. Sharpe : 3,69 / 2,82 contre $-0,21$ / $-0,40$.
- Univers : S&P 500, point-in-time, 05/03/2010–15/03/2018 (7 périodes annuelles, cf. Table 1 du papier), 415 tickers.

Découpage formation / trading

- L'historique est découpé en blocs consécutifs de 252 jours ouvrés.
- Pour chaque période n :
 - formation = bloc k (in-sample),
 - trading = bloc $k + 1$ (out-of-sample).
- La sélection des paires se fait **uniquement** sur le bloc de formation, à partir de l'univers survivant à cette date (aucun look-ahead bias).

Distance	20 paires minimisant $\sum (P_i^* - P_j^*)^2$ sur les prix normalisés.
Cointégration	Test ADF d'Engle-Granger sur $\tilde{P}_i - \alpha - \beta \tilde{P}_j$ après pré-filtre par distance.

L'étape ondelettes

- Chaque série de prix est rééchelonnée, $\tilde{P}_t = P_t/P_0$.
- MODWT niveau 1+ avec le **symlet sym20**, condition aux bords périodique sur le bloc de trading (fidèle au papier, section 4.4).
- On conserve les **coefficients lisses** (passe-bas), on jette les détails (passe-haut), puis on reconstitue le prix synthétique.
- Le spread de la paire filtrée par ondelettes est alors

$$s_t = \tilde{P}_i^{\text{wav}} - \alpha - \beta \tilde{P}_j^{\text{wav}},$$

avec (α, β) estimés par MCO sur le bloc de formation.

- La variante standard utilise la même formule *sans* l'étape MODWT — c'est la seule différence entre les courbes de chaque figure.

Règle de trading

- Calculer σ du spread sur la fenêtre de formation.
- Entrer dès que $|s_t| > 2\sigma$ (vente du jambage haut, achat du jambage bas).
- Sortir quand s_t recroise zéro pour la première fois.
- Clôture forcée en fin de bloc de trading ; la variante **forced-close-only** de la Table 22 n'utilise aucune autre sortie.
- Coûts de transaction : coût par action appliqué à l'entrée et à la sortie. Nous balayons $tc \in \{0 ; 0,001 ; 0,005\}$ pour les Tables 18–21.

Architecture de la réplication

<code>research/main.py</code>	CLI unifiée. <code>-full</code> = run complet du papier, <code>-tc-sweep</code> = Tables 18–21.
<code>paper_replication/core/</code>	Moteur par période : periods, selection, spread, trading, wavelet, metrics.
<code>paper_replication/analytics/</code>	Régressions d'asset pricing (Fama-French, q-factor, ICAPM de Petkova).
<code>paper_replication/outputs/</code>	22 tables numérotées + 12 figures + résumé de validation.
<code>paper_replication/bootstrap/</code>	Récupération Bloomberg et rafraîchissement des facteurs CSV.

- Polars + numpy + statsmodels (HAC Newey–West), export PNG via matplotlib.
- Sélection des paires et trading : Python pur, déterministe, sans MATLAB.
- 31 tests unitaires (`py -m pytest -q`) couvrant pipeline, tables et seuils de validation.

Chiffres-clés (Tables 4 & 5)

Méthode	Rendement moyen (%)		Sharpe	
	Standard	Ondelettes	Standard	Ondelettes
Distance	−0,55	11,82	−0,21	3,69
Cointégration	−1,81	9,66	−0,40	2,82

Les tolérances de réplcation sont dans `paper_validation_summary.csv` : PASS si $|\Delta\text{mean}| \leq 1,0$ pp et $|\Delta\text{Sharpe}| \leq 0,30$.

Figure 4 — Rendements cumulés en excès

Figure 4 - Cumulative returns (distance)





Figure 4 - Cumulative returns (cointegration)



Gauche : méthode des distances. Droite : méthode de cointégration.

Figure 5 — Ratios de Sharpe quotidiens

Figure 5 - Daily Sharpe-ratio evolution (distance)



Figure 5 - Daily Sharpe-ratio evolution (cointegration)




Figure 8 — Corrélation du bruit filtré

Figure 8 - Filtered-noise variance vs unfiltered return (distance); $\text{corr}=0.19$




Figure 8 - Filtered-noise variance vs unfiltered return (cointegration); $\text{corr}=-0.32$




Figure 9 — Rendements anormaux annuels

Figure 9 - Yearly market-model alpha (distance); green = significant at 5%





Figure 9 - Yearly market-model alpha (cointegration); green = significant at 5%



Couverture de la réplcation

Éléments	Statut	Notes
Tables 1–9	reproduites	run par défaut
Table 10	reproduite	ACP, Python pur (auparavant marquée MATLAB-only)
Tables 11, 13–15	reproduites	nécessitent <code>research/data/factors.csv</code>
Table 12	reproduite	Monte-Carlo contamination MODWT
Tables 16–17	reproduites	balayages classe d'ondelettes et horizon
Tables 18–21	opt-in	<code>-tc-sweep 0.0 0.001 0.005</code>
Table 22	reproduite	forced-close-only (paires standard)
Figures 1–12	reproduites	matplotlib, PNG style papier
Résumé de validation	livré	<code>paper_validation_summary.csv</code>

L'ensemble des 22 tables numérotées et des 12 figures est produit par une seule commande :

```
py research/main.py -full -tc-sweep 0.0 0.001 0.005
```

Merci de votre attention

Code de réplication, slides et sorties :
sous-arbre `research/` du backtesting framework.

Yassine Mannai · Antonin Bezard · Issam Fradi
Université Paris-Dauphine — Master 272 — Arbitrage Statistique